Variantenanalyse zweier humaner Gesamtgenome (NA12878 und NA12877): von den Rohdaten zu annotierten ClinVar-Kandidaten und einem Elternvergleich

Karim Andjar

Masterstudiengang Bioinformatik und Systembiologie, Justus-Liebig-Universität Gießen

Zusammenfassung. Ich habe für zwei Proben des Platinum-Genomes-Pedigrees, NA12878 (Mutter, ERR194147) und NA12877 (Vater, ERR194146), jeweils eine Pipeline von den Rohdaten (Illumina-Paired-End, rund 50-fache Tiefe) bis zu annotierten ClinVar-Kandidaten aufgebaut und mit Snakemake umgesetzt: Qualitätskontrolle und Trimming (fastp), Mapping (BWA-MEM gegen GRCh38), Duplikatmarkierung (GATK), Variantenbestimmung (HaplotypeCaller) und Annotation (VEP mit ClinVar). Es wurden 4.893.226 (Mutter) und 4.889.622 (Vater) Varianten gefunden. Ein strenger Filter auf *Pathogenic* und *Likely pathogenic* lieferte je 11 Kandidaten. Die Pipeline enthält keinen Variantenfilter; deshalb habe ich die Kandidaten anhand von Allelbalance, Tiefe und Genotypqualität nachgeprüft. Dabei fielen vier (Mutter) bzw. drei (Vater) Treffer als Artefaktverdacht heraus; es blieben 7 bzw. 6 Kandidaten, von denen 3 bzw. 4 als belastbar gelten. Der Vergleich beider Genome ergab kein Gen, in dem beide Eltern eine belastbare Variante tragen. Ein Abgleich der ungefilterten Calls mit den Platinum-Genomes-Referenzcalls ergab innerhalb der Konfidenzregionen für SNVs eine Präzision und Sensitivität von rund 99,3 %, für Indels von rund 97 %. Die Ergebnisse sind ClinVar-Annotationen und keine Diagnosen.

Abstract. For two samples of the Platinum Genomes pedigree, NA12878 (mother) and NA12877 (father), I built a Snakemake pipeline from raw Illumina paired-end reads (about 50-fold coverage) to ClinVar-annotated candidate variants (fastp, BWA-MEM on GRCh38, GATK MarkDuplicates and HaplotypeCaller, VEP). About 4.89 million variants were called per genome, and a strict filter for *Pathogenic* and *Likely pathogenic* yielded 11 candidates each. Because the pipeline applies no variant filter, candidates were checked by allele balance, depth and genotype quality; 7 (mother) and 6 (father) remained, of which 3 and 4 are considered reliable. No gene carries a reliable candidate in both parents. Against the Platinum Genomes reference calls, the unfiltered calls reached precision and sensitivity of about 99.3 % for SNVs and about 97 % for indels within the confident regions. Results are ClinVar annotations, not diagnoses.

1 Einleitung

Die Sequenzierung ganzer Genome liefert pro Person einige Millionen Abweichungen von der Referenz. Nur ein sehr kleiner Teil davon ist klinisch relevant, und ein noch kleinerer Teil lässt sich technisch zuverlässig nachweisen. Ziel dieser Arbeit war, den gesamten Weg von den Rohdaten bis zu einer überschaubaren Liste annotierter Kandidaten nachvollziehbar und reproduzierbar umzusetzen und kritisch zu prüfen, welche Treffer belastbar sind.

Als Material dienen zwei Genome des Platinum-Genomes-Pedigrees (Eberle et al., 2017): NA12878 und NA12877, die im Pedigree als Eltern geführt werden. Beide Proben wurden mit derselben Pipeline verarbeitet. Das erlaubt eine Demonstration des Prinzips der Trägerschaftsanalyse: Tragen beide Eltern eine Variante im selben Gen, und wirkt diese rezessiv, so beträgt das Risiko für ein Kind, beide Kopien zu erben, 25 %; trägt nur ein Elternteil die Variante, ist ein Kind mit 50 % Wahrscheinlichkeit Träger. Diese Rechnung ist hier ein Rechenbeispiel auf öffentlich verfügbaren Daten und keine Risikoabschätzung für reale Personen.

2 Material und Methoden

2.1 Daten

Verwendet wurden die Illumina-Paired-End-Daten ERR194147 (NA12878) und ERR194146 (NA12877) mit einer Leselänge von etwa 101 bp. Referenz war GRCh38.

2.2 Vorverarbeitung und Mapping

Die Rohdaten wurden mit FastQC (Andrews, 2010) geprüft und mit fastp (Chen et al., 2018) von Adaptern und Basen schlechter Qualität bereinigt. Das Mapping erfolgte mit BWA-MEM (Li, 2013), Duplikate wurden mit GATK MarkDuplicates markiert (McKenna et al., 2010). Eine Rekalibrierung der Basenqualitäten (BQSR) wurde nicht durchgeführt.

2.3 Variantenbestimmung

Varianten wurden mit dem GATK-HaplotypeCaller (McKenna et al., 2010; Van der Auwera et al., 2013) im Einzelprobenmodus bestimmt. Ein nachgeschalteter Variantenfilter (VQSR oder Hard Filter) ist in der Pipeline nicht enthalten. Die VCF-Dateien sind daher

ungefiltert; das Ti/Tv-Verhältnis wurde mit bcftools (Danecek et al., 2021) bestimmt.

2.4 Annotation und Kandidatenfilter

Die Annotation erfolgte mit dem Ensembl Variant Effect Predictor (VEP, Release 116; McLaren et al., 2016) unter Verwendung von ClinVar (Landrum et al., 2018). Als streng gelten Varianten, deren ClinVar-Klassifikation mit *Pathogenic* oder *Likely pathogenic* beginnt; Einträge mit widersprüchlicher Klassifikation zählen nicht dazu. Die Klassen folgen der üblichen Terminologie (Richards et al., 2015). Die Prüfsterne (0 bis 4) geben an, wie gut ein ClinVar-Eintrag abgesichert ist (0: keine Prüfkriterien, 1: ein Einreicher, 2: mehrere Einreicher ohne Widerspruch, 3: Expertengremium, 4: Praxisleitlinie).

2.5 Qualitätsklassen der Kandidaten

Aus dem AD-Feld der VCF-Datei wurde die Allelbalance AB als Anteil der Alt-Reads an allen Reads am Locus berechnet. Ein echter heterozygoter Genotyp liegt nahe 0,5. Die Kandidaten wurden in drei Klassen eingeteilt:

- *belastbar*: heterozygot mit AB 0,35–0,75, Tiefe (DP) ≥ 15 und Genotypqualität (GQ) ≥ 30; homozygot (1/1) mit AB $\geq 0{,}85$ und denselben Mindestwerten;
- *unsicher*: alle übrigen Fälle, ausdrücklich auch Indels mit AB $< 0{,}25$, da der AD-Wert bei Indels systematisch zu niedrig ausfällt;
- *Artefaktverdacht*: SNVs mit AB $< 0{,}25$ (heterozygot) bzw. AB $< 0{,}5$ (homozygot); sie werden verworfen.

Die Schwellen sind pragmatisch gewählt und nicht an einem Truth Set optimiert.

2.6 Validierung

Die Variantenbestimmung wurde mit den Platinum-Genomes-Referenzcalls (Version 2017-1.0, GRCh38; Eberle et al., 2017) für NA12878 und NA12877 geprüft. Verglichen wurden die ungefilterten VCF-Dateien innerhalb der mitgelieferten Konfidenzregionen mit rtg vcfeval (RTG Tools 3.13), das auch unterschiedliche Schreibweisen derselben Variante abgleicht. Die Chromosomennamen des Truth Sets (`chr1`) wurden an die Referenz (`1`) angepasst. Das Truth Set enthält nur die Chromosomen 1–22 und X; Y-Chromosom und Mitochondrium sind daher nicht bewertet. Maße sind Präzision, TP/(TP+FP), und Sensitivität, TP/(TP+FN), getrennt für SNVs und übrige Varianten (Indels und komplexe Varianten).

2.7 Workflow und Visualisierung

Die Pipeline ist mit Snakemake (Mölder et al., 2021) umgesetzt; die Probe wird über die Konfiguration (`sample`, `name`) gewählt. Der Kandidatenfilter, der Elternvergleich und die Abbildungen sind eigenständige Python-Skripte außerhalb von Snakemake. Abbildungen wurden mit Matplotlib (Hunter, 2007) erstellt. Zur Einordnung der Geschlechtschromosomen wurde die Tiefe von X und Y relativ zum Median der Autosomen berechnet.

Tabelle 1: Qualitätskennzahlen der beiden Proben.

	Mutter NA12878	Vater NA12877
Reads vor fastp (Mio.)	1.574,5	1.626,4
Reads nach fastp (Mio.)	1.531,9	1.584,4
Q30 nach fastp (%)	93,3	91,8
Abgebildet (%)	99,74	99,60
Korrekt gepaart (%)	97,93	97,66
Duplikate (%)	1,18	1,19
Median Tiefe Autosomen	51×	54×
Relative Tiefe X / Y	0,97 / 0,093	0,50 / 0,411

3 Ergebnisse

3.1 Sequenzierung und Mapping

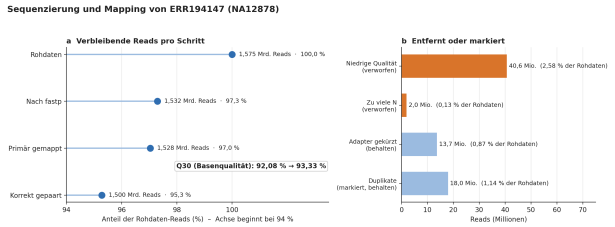
Tabelle 1 fasst die Qualitätskennzahlen beider Proben zusammen. Beide Datensätze sind vergleichbar: Nach dem Trimming blieben 97,3 % (Mutter) bzw. 97,4 % (Vater) der Reads übrig, die Q30-Anteile stiegen auf 93,3 % bzw. 91,8 %, und 99,7 % bzw. 99,6 % der Reads ließen sich abbilden. Die Duplikationsrate liegt in beiden Fällen bei rund 1,2 %. Die mittlere Tiefe beträgt etwa 50-fach, der Median der Autosomen 51-fach (Mutter) bzw. 54-fach (Vater). Die relative Tiefe von X und Y (Mutter 0,97 und 0,093; Vater 0,50 und 0,411) entspricht einer weiblichen bzw. männlichen Probe und bestätigt die Zuordnung (Abb. 2).

3.2 Varianten

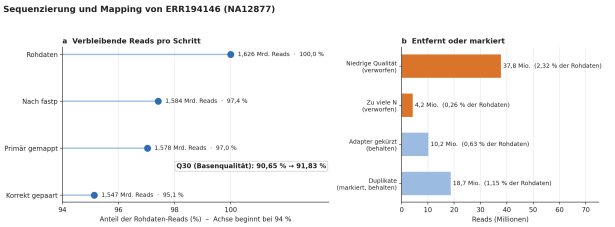
Der HaplotypeCaller lieferte 4.893.226 (Mutter) bzw. 4.889.622 (Vater) Varianten (Tab. 2, Abb. 3). Das Ti/Tv-Verhältnis liegt in beiden Proben bei 1,98 und das Verhältnis heterozygoter zu homozygoten Varianten bei 1,70 bzw. 1,64, was für humane Gesamtgenome im üblichen Bereich liegt. Auf dem Y-Chromosom wurden in beiden Proben rund 14.000 Varianten gefunden; bei der weiblichen Probe sind sie Mapping-Artefakte aus Sequenzen, die auch auf X oder in Wiederholungen vorkommen, und auch beim männlichen Genom dürfte ein Großteil darauf zurückgehen.

3.3 Validierung gegen Referenzcalls

Innerhalb der Konfidenzregionen stimmen die ungefilterten Calls weitgehend mit den Referenzcalls überein (Tab. 3). Für SNVs liegen Präzision und Sensitivität in beiden Proben bei rund 99,3 %. Bei Indels und komplexen Varianten sind sie mit 96,8 bis 97,4 %

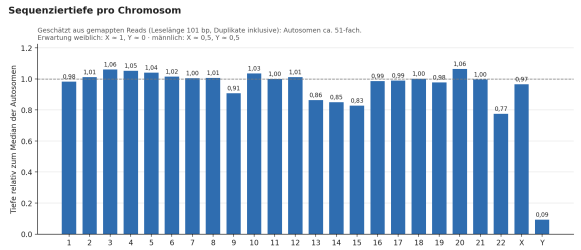


(a) Mutter (NA12878)

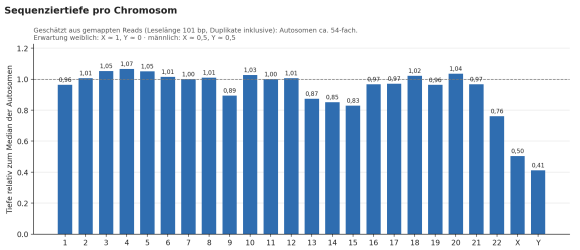


(b) Vater (NA12877)

Abbildung 1: Anteil der Reads nach jedem Verarbeitungsschritt sowie entfernte und markierte Reads.



(a) Mutter (NA12878)



(b) Vater (NA12877)

Abbildung 2: Sequenziertiefe pro Chromosom relativ zum Median der Autosomen.

Tabelle 2: Varianten pro Probe (Chromosomen 1–22, X, Y). Rund 84.000 weitere Varianten liegen auf Contigs.

	Mutter	Vater
SNVs	3.970.524	3.957.389
Insertionen	372.923	381.250
Deletionen	397.247	402.146
Multiallelisch	68.136	70.438
Ti/Tv	1,98	1,98
Het/Hom	1,70	1,64

Tabelle 3: Abgleich der ungefilterten Calls mit den Platinum-Genomes-Referenzcalls innerhalb der Konfidenzregionen (rtg vcfeval). TP: richtig gefundene Varianten, FP: falsch gefundene, FN: übersehene; Pr.: Präzision, Sens.: Sensitivität (in %). Indels u. a.: Insertionen, Deletionen und komplexe Varianten.

	TP	FP	FN	Pr.	Sens.
Mutter, SNVs	3.571.506	25.874	23.666	99,28	99,34
Mutter, Indels u. a.	554.398	15.612	18.330	97,26	96,80
Mutter, gesamt	4.125.904	41.486	41.996	99,00	98,99
Vater, SNVs	3.553.886	25.683	23.650	99,28	99,34
Vater, Indels u. a.	554.354	15.040	15.763	97,36	97,24
Vater, gesamt	4.108.240	40.723	39.413	99,02	99,05

niedriger; das passt dazu, dass Insertionen und Deletionen in Wiederholungen mit kurzen Reads schwerer zu bestimmen sind. Insgesamt betragen Präzision und Sensitivität rund 99,0 % (F-Maß 0,9900 bei der Mutter, 0,9903 beim Vater). Ein Schwellenwert auf QUAL verbessert das kaum (F-Maß 0,9901 bzw. 0,9904); die Fehler lassen sich also nicht durch einen einfachen QUAL-Filter beseitigen.

Tabelle 4: Filtertrichter pro Probe.

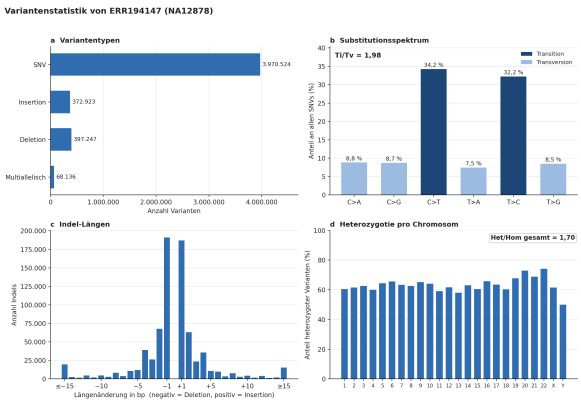
Stufe	Mutter	Vater
Varianten gesamt	4.893.226	4.889.622
VEP-annotiert	4.864.560	4.864.034
mit ClinVar-Eintrag	44.476	43.890
pathogen (weit gefasst)	181	188
streng (P/LP)	11	11
davon proteinverändernd	11	9
nach Qualitätsfilter	7	6

3.4 Annotation und Filtertrichter

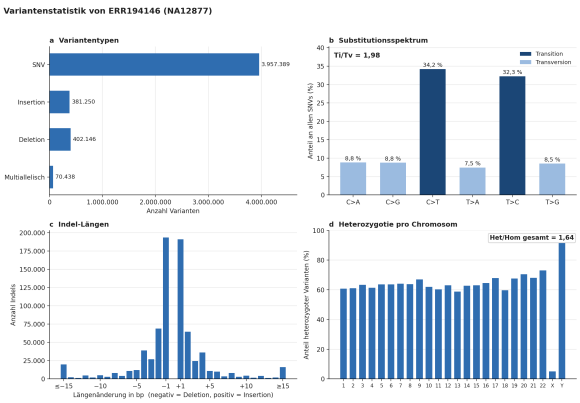
VEP annotierte 4.864.560 (Mutter) bzw. 4.864.034 (Vater) Varianten. Die Differenz zu den gerufenen Varianten beträgt in beiden Proben etwa 0,6 %. Sie liegt vollständig auf Contigs außerhalb der Chromosomen 1–22, X und Y: Auf diesen Chromosomen wurden alle Varianten annotiert (4.808.830 bzw. 4.811.223), von den Contig-Varianten (84.396 bzw. 78.399) fehlen 28.666 bzw. 25.588 in der VEP-Ausgabe. Für rund 44.000 Varianten gab es einen ClinVar-Treffer, überwiegend als „Benign“ (Tab. 4). Als pathogen im weiten Sinn blieben 181 bzw. 188 Varianten, davon jeweils nur 11 mit eindeutiger Klassifikation; der Rest hat eine widersprüchliche Klassifikation. Beim Vater sind 9 der 11 Treffer proteinverändernd, bei der Mutter alle 11. Der anschließende Qualitätsfilter (Abschnitt 3.5) reduziert die Liste auf 7 bzw. 6 Kandidaten (Abb. 5).

3.5 Kandidaten

Alle verbleibenden Kandidaten sind heterozygot. Tabelle 5 zeigt die Ergebnisse nach Qualitätsprüfung; die Krankheitsangaben und Prüfsterne stammen aus ClinVar und geben dessen Wortlaut wieder. Abbildung 7

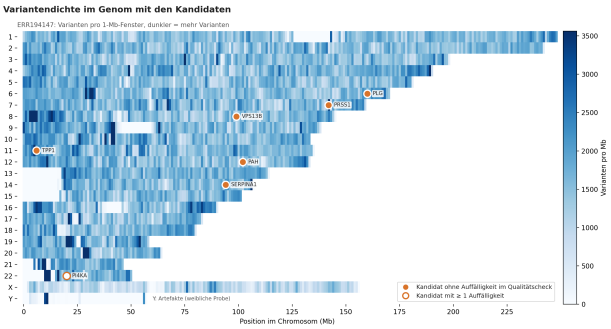


(a) Mutter (NA12878)

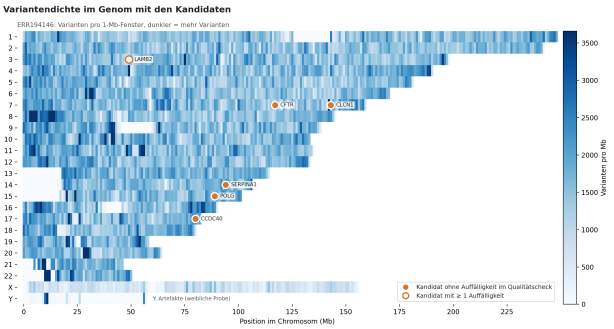


(b) Vater (NA12877)

Abbildung 3: Variantenstatistik: Variantentypen, Substitutionsspektrum mit Ti/Tv, Indel-Längen und Anteil heterozygoter Varianten pro Chromosom.

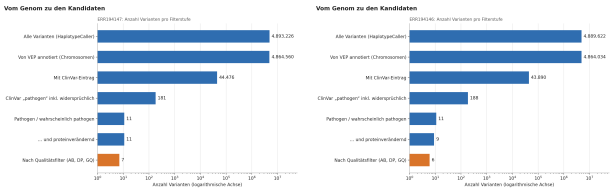


(a) Mutter (NA12878)



(b) Vater (NA12877)

Abbildung 4: Variantendichte pro Megabase und Lage der Kandidaten.



(a) Mutter

(b) Vater

Abbildung 5: Filtertrichter von allen Varianten bis zu den Kandidaten nach Qualitätsfilter.

zeigt die Allelbalance aller Treffer.

Belastbare Kandidaten. Bei der Mutter sind *TPP1*, *PAH* und *PLG* belastbar, beim Vater *POLG*, *CCDC40*, *CFTR* und *CLCN1*. Der *CFTR*-Eintrag besitzt mit vier Sternen die höchste Absicherung in ClinVar. Die Krankheitsangaben laut ClinVar lauten *TPP1*: TPP1-related disorder, *PAH*: Hyperphenylalaninemia, *CFTR*: Cystic fibrosis, *CCDC40*: Primary ciliary dyskinesia und *CLCN1*: Skeletal muscle channelopathy. *PLG* (Plasminogen) und *POLG* (Sensory ataxic neuropathy, dysarthria, and ophthalmoparesis) sind ebenfalls ClinVar-Einträge; die Vererbung hängt bei diesen Genen vom Krankheitsbild ab.

Unsichere Kandidaten. Alle unsicheren Treffer haben niedrige Allelbalance. Bei *PRSS1* (AB 0,32) liegt der Locus in einer Region mit Paralogen (*PRSS2*, *PRSS3*); die Mapping-Qualität ist dort eingeschränkt. Bei *VPS13B* stützen nur drei Alt-Reads (Tiefe 17) die Deletion. Bei *PI4KA* haben knapp 19 % der Reads am Locus eine niedrige Mapping-Qualität; die Region enthält Pseudogene (22q11.2), und QD ist mit 1,12 niedrig. Bei *LAMB2* (Vater) sind QD 1,04, SOR 4,97 und FS 44,9 auffällig, bei *SERPINA1* erhöhte SOR- und FS-Werte (Mutter: FS 34,6, SOR 4,97). Diese Einträge sollten ohne unabhängige Bestätigung nicht als echte Varianten betrachtet werden.

Verworfene Treffer. Als Artefaktverdacht wurden bei der Mutter *TUBB8* (AB 0,14, subtelomerisch), zwei Positionen in *CNN2* (AB 0,20 und 0,17, GC-reiche Region) und eine zweite *PRSS1*-Position (AB 0,12) verworfen, beim Vater zwei Positionen in *CNN2* (AB 0,13) und *PRSS1* 7:142750561 (AB 0,20).

3.6 Vergleich der Eltern

Gemeinsam in beiden Genomen erscheint nur *SERPINA1*, und zwar als dieselbe Variante (14:94379549 A>AG) mit niedriger Allelbalance (0,17 bzw. 0,13). Bei diesem Eintrag stimmen zwei Dinge nicht zu ei-

Tabelle 5: Kandidaten beider Eltern nach Qualitätsprüfung (GRCh38). AB: Allelbalance; Sterne: ClinVar-Prüfstatus. Krankheitsangaben laut ClinVar, keine Diagnosen.

Probe	Gen	Position	Variante / Effekt	AB	Sterne	Klasse
Mutter	*TPP1*	11:6617154	C>T, Spleißakzeptor	0,66	2	belastbar
	PAH	12:102840474	T>C, Missense	0,61	3	belastbar
	PLG	6:160706469	A>G, Missense	0,39	2	belastbar
	PRSS1	7:142750561	C>T	0,32	2	unsicher
	SERPINA1	14:94379549	A>AG, Frameshift	0,17	1	unsicher
	VPS13B	8:99832366	TAGTA>T, Spleißakzeptor	0,18	1	unsicher
	PI4KA	22:20709921	TTGTC>T, Frameshift	0,10	2	unsicher
Vater	*POLG*	15:89327201	C>T	0,53	2	belastbar
	CCDC40	17:80039965	GC>G, Frameshift	0,62	2	belastbar
	CFTR	7:117587738	G>A, Spleißakzeptor	0,47	4	belastbar
	CLCN1	7:143351678	C>T, Stop gained	0,61	2	belastbar
	LAMB2	3:49132597	T>G, Missense	0,28	0	unsicher
	SERPINA1	14:94379549	A>AG, Frameshift	0,13	1	unsicher

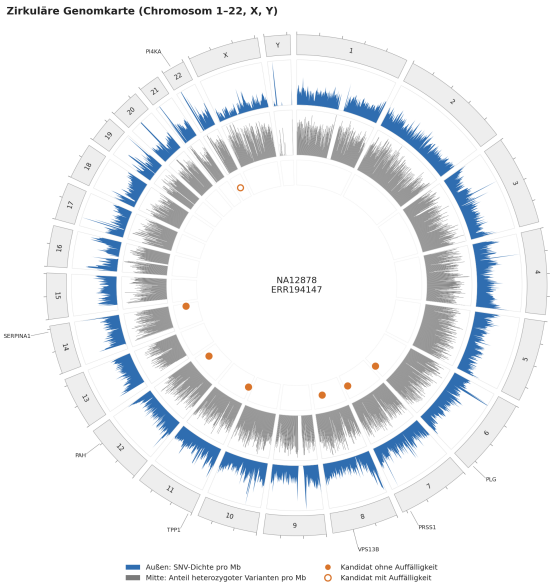


Abbildung 6: Zirkuläre Genomkarte der Mutter mit SNV-Dichte, Anteil heterozygoter Varianten und Kandidaten (Vater: `abbildungen/ERR194146/7_circos.png`).

nem echten Befund: Die Allelbalance liegt weit unter 0,5, und in den Roh-Alignments konnte ich die Insertion nicht bestätigen. Ein Gleiches gilt für *PRSS1* 7:142750561, das beim Vater verworfen und bei der Mutter nur als unsicher eingestuft wurde, und für *CNN2*, das in beiden Proben im Artefaktbereich liegt. Dass dieselben Positionen in beiden unabhängigen Genomen auftreten, spricht eher für einen systematischen Mapping- oder Calling-Artefakt als für eine echte gemeinsame Variante; ein Abgleich mit Populationsfrequenzen (gnomAD) steht noch aus. Das ClinVar-Krankheitsbild des *SERPINA1*-Eintrags (Pneumothorax – familial) passt zudem nicht zu dem, was man bei diesem Gen erwarten würde, und sollte nicht als Alpha-1-Antitrypsin-Mangel gelesen werden.

Unter den belastbaren Kandidaten gibt es daher kein gemeinsames Gen. Die Mutter trägt Varianten in *TPP1*, *PAH* und *PLG*, der Vater in *POLG*, *CCDC40*, *CFTR* und *CLCN1*. Für klassisch rezessive Erkrankungen wie *TPP1*, *PAH*, *CFTR* und *CCDC40* bedeutet das: Ein gemeinsames Kind hätte für jede dieser Varianten, die nur ein Elternteil trägt, eine Wahrscheinlichkeit von 50 %, Träger zu sein, aber kein erhöhtes Risiko, selbst zu erkranken, da die zweite Kopie aus dem anderen Elternteil unauffällig wäre. Nur wenn beide Eltern dieselbe rezessive Variante (oder zwei Varianten im selben Gen) tragen, ergibt sich das 25-%-Risiko mit 50 % Trägern und 25 % ohne Variante. Der Erbgang ist in den Tabellen nicht enthalten und müsste für jedes Gen in der Literatur nachgeschlagen werden.

4 Diskussion

Die beiden Genome sind technisch vergleichbar (Tab. 1, 2); Mapping-Rate, Duplikationsrate, Ti/Tv und Het/Hom-Verhältnis liegen im erwarteten Bereich. Das wichtigste inhaltliche Ergebnis ist, dass der strenge ClinVar-Filter ohne Qualitätsprüfung ein falsches Bild gezeichnet hätte: Von je 11 Treffern blieben nach Prüfung nur 7 bzw. 6, und nur 3 bzw. 4 sind belastbar. Mehrere der verworfenen Treffer liegen in Regionen, die für Mapping-Probleme bekannt sind (Paraloge, Pseudogene, GC-reiche oder subtelomerische Bereiche). Ein ungefilterter Variantensatz führt hier also zu Scheintreffern; ein Hard Filter oder VQSR sowie BQSR wären in einer produktiven Pipeline erforderlich. Die hohe Übereinstimmung mit den Referenzcalls gilt nur innerhalb der Konfidenzregionen; schwierige Regionen, aus denen Mapping-Artefakte typischerweise stammen, sind darin nicht enthalten.

Die Allelbalance ist ein pragmatisches, aber grobes Kriterium. Sie ist bei Indels verzerrt, weshalb diese bei niedriger AB nur als unsicher und nicht als Artefakt gelten. Die Einstufung *unsicher* heißt deshalb nicht, dass die Variante falsch ist, sondern dass die Daten sie nicht ausreichend belegen.

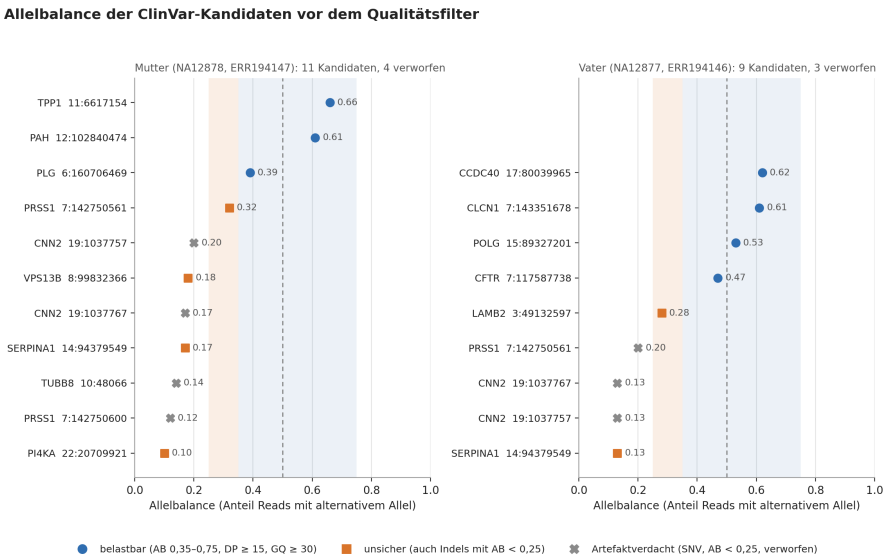


Abbildung 7: Allelbalance der Treffer beider Eltern, farblich nach Qualitätsklasse. Heterozygote Varianten liegen bei etwa 0,5; Indels sind wegen verzerrter AD-Werte gesondert behandelt.



(a) Mutter (NA12878)



(b) Vater (NA12877)

Abbildung 8: Qualitätswerte der Kandidaten.

5 Einschränkungen

- **Eingeschränkte Validierung.** Der Abgleich mit den Platinum-Genomes-Referenzcalls gilt nur für die Konfidenzregionen (Chromosomen 1–22 und X), nicht für schwierige Regionen, das Y-Chromosom und das Mitochondrium. Das Truth Set beruht auf Sequenzdaten desselben Pedigrees (Eberle et al., 2017) und ist daher nicht vollständig unabhängig; die Werte können die tatsächliche Genauigkeit überschätzen. Ein Vergleich mit einem unabhängigen Truth Set (GIAB, Zook et al., 2014) steht noch aus.

- Kein Variantenfilter (VQSR/Hard Filter), kein BQSR; die Schwellen des Kandidatenfilters sind nicht kalibriert.

- *SERPINA1* wurde in den Roh-Alignments nicht bestätigt; die Hinweise auf systematische Artefakte (*PRSS1*, *CNN2*, *SERPINA1* in beiden Proben) sind nicht durch Populationsfrequenzen abgesichert.

- Etwa 0,6 % der gerufenen Varianten tauchen in der VEP-Ausgabe nicht auf. Sie liegen alle auf Contigs außerhalb der Chromosomen 1–22, X und Y; den Grund dafür und ob darunter ClinVar-Einträge liegen, habe ich nicht untersucht.

- ClinVar-Klassifikationen sind teils älter oder nur von einem Einreicher abgesichert; Sterne und Krankheitsbezeichnungen sind hier wörtlich wiedergegeben und nicht fachlich neu bewertet.

- Es wurden nur SNVs und kleine Indels betrachtet; Strukturvarianten, Kopienzahl und Mitochondrium wurden nicht ausgewertet.

- Die Ergebnisse sind keine Diagnosen und ersetzen keine humangenetische Beratung.

6 Ausblick

Als nächste Schritte sind ein Abgleich mit einem unabhängigen Truth Set (GIAB), ein Variantenfilter nach GATK-Empfehlung, die Prüfung der unsicheren Treffer in IGV und der Abgleich mit Populationsfrequenzen vorgesehen.

7 Schlussfolgerung

Die Pipeline verarbeitet zwei Gesamtgenome reproduzierbar von den Rohdaten bis zu annotierten Kandidaten; die ungefilterten Calls stimmen innerhalb der Konfidenzregionen zu rund 99 % mit den Platinum-Genomes-Referenzcalls überein. Die Qualitätsprüfung zeigt, dass ein strenger ClinVar-Filter allein nicht ausreicht: Erst die Kombination mit Allelbalance, Tiefe und Genotypqualität trennt belastbare Treffer von Mapping-Artefakten. Im Elternvergleich ergab sich kein Gen mit belastbaren Varianten bei beiden Eltern. Alle Aussagen sind ClinVar-Annotationen ohne Diagnosewert.

Datenverfügbarkeit

Die Rohdaten sind öffentlich verfügbar (ENA: ERR194147, ERR194146). Code und Konfiguration der Pipeline stehen im Projektverzeichnis bzw. im zugehörigen GitHub-Repository.

Literatur

Simon Andrews. FastQC: a quality control tool for high throughput sequence data. `https://www.bioinformatics.babraham.ac.uk/projects/fastqc/`, 2010.

Shifu Chen, Yanqing Zhou, Yaru Chen, and Jia Gu. fastp: an ultra-fast all-in-one FASTQ preprocessor. *Bioinformatics*, 34(17):i884–i890, 2018. doi: 10.1093/bioinformatics/bty560.

Petr Danecek, James K. Bonfield, Jennifer Liddle, et al. Twelve years of SAMtools and BCFtools. *GigaScience*, 10(2):giab008, 2021. doi: 10.1093/gigascience/giab008.

Michael A. Eberle, Epameinondas Fritzilas, Peter Krusche, et al. A reference data set of 5.4 million phased human variants validated by genetic inheritance from sequencing a three-generation 17-member pedigree. *Genome Research*, 27(1):157–164, 2017. doi: 10.1101/gr.210500.116.

John D. Hunter. Matplotlib: a 2D graphics environment. *Computing in Science & Engineering*, 9(3): 90–95, 2007. doi: 10.1109/MCSE.2007.55.

Melissa J. Landrum, Jennifer M. Lee, Mark Benson, et al. ClinVar: improving access to variant interpretations and supporting evidence. *Nucleic Acids Research*, 46(D1):D1062–D1067, 2018. doi: 10.1093/nar/gkx1153.

Heng Li. Aligning sequence reads, clone sequences and assembly contigs with BWA-MEM. arXiv:1303.3997, 2013. URL `https://arxiv.org/abs/1303.3997`.

Aaron McKenna, Matthew Hanna, Eric Banks, et al. The Genome Analysis Toolkit: a MapReduce framework for analyzing next-generation DNA sequencing data. *Genome Research*, 20(9):1297–1303, 2010. doi: 10.1101/gr.107524.110.

William McLaren, Laurent Gil, Sarah E. Hunt, et al. The Ensembl Variant Effect Predictor. *Genome Biology*, 17:122, 2016. doi: 10.1186/s13059-016-0974-4.

Felix Mölder, Kim Philipp Jablonski, Brice Letcher, et al. Sustainable data analysis with Snakemake. *F1000Research*, 10:33, 2021. doi: 10.12688/f1000research.29032.2.

Sue Richards, Nazneen Aziz, Sherri Bale, et al. Standards and guidelines for the interpretation of sequence variants: a joint consensus recommendation of the American College of Medical Genetics and Genomics and the Association for Molecular Pathology. *Genetics in Medicine*, 17(5):405–424, 2015. doi: 10.1038/gim.2015.30.

Geraldine A. Van der Auwera, Mauricio O. Carneiro, Chris Hartl, et al. From FastQ data to high-confidence variant calls: the Genome Analysis Toolkit best practices pipeline. *Current Protocols in Bioinformatics*, 43(1):11.10.1–11.10.33, 2013. doi: 10.1002/0471250953.bi1110s43.

Justin M. Zook, Brad Chapman, Jason Wang, et al. Integrating human sequence data sets provides a resource of benchmark SNP and indel genotype calls. *Nature Biotechnology*, 32(3):246–251, 2014. doi: 10.1038/nbt.2835.